

AFRICA IMPACT STUDIO

Les Gardiens du Quartier

GUARDIAN AI

« Le Gardien »

Blueprint Technique Complet

Architecture d'un assistant éducatif IA (RAG) pour la protection et l'éducation des enfants en Afrique

Ecrit par: ING. KOUOTOU AHMAD BILAL

Document de conception technique — Modules 0 à 12

Juillet 2026

Table des Matières

Table des Matières.....	2
Module 0 — Configuration du Projet	6
Récapitulatif de Configuration	6
Charte de Projet	7
Vision	7
Mission	7
Objectifs	7
Périmètre.....	7
Inclus dans cette phase.....	7
Hors périmètre pour cette phase	7
Indicateurs de Succès.....	7
Parties Prenantes	8
Risques Principaux	8
Principes Éthiques.....	8
Module 1 — Vision Produit, Mission, Périmètre, Objectifs.....	9
1. Résumé Exécutif	9
2. Explication Détaillée	9
Ce qu'est Guardian AI	9
Ce que Guardian AI n'est pas	9
3. Architecture — Vue Produit	9
4. Décisions Techniques	10
5. Compromis	11
6. Risques	11
7. Recommandations	11
8. Décisions Validées avec le Porteur de Projet.....	11
Module 2 — Exigences Fonctionnelles	12
1. Résumé Exécutif	12
2. User Stories	12
Enfant (6–9 ans)	12
Enfant (10–14 ans)	12
Enfant (15–18 ans)	12
Parent	12
Enseignant	12
3. Capacités	12
4. Limitations Explicites	12
5. Cas d'Usage	13
6. Exigences Non-Fonctionnelles	13

7. Décisions Validées.....	13
Module 3 — Architecture Complète des Connaissances	14
1. Résumé Exécutif	14
2. Séparation Contenu Éducatif / Contenu Protocole	14
3. Architecture — Taxonomie des Connaissances	14
4. Domaines de Connaissance	14
5. Hiérarchie de la Connaissance	14
6. Cycle de Vie de la Connaissance	14
7. Gouvernance	15
8. Décisions Validées.....	15
Module 4 — Schéma de Connaissance Guardian.....	16
1. Résumé Exécutif	16
2. Schéma Complet — Champs et Spécifications	16
2.1 Identification et Classification	16
2.2 Ciblage et Adaptation	16
2.3 Contenu Pédagogique	16
2.4 Ancrage Narratif	16
2.5 Sources, Validation et Gouvernance	17
3. Architecture — Relations entre Blocs du Schéma	17
4. Décisions Techniques	17
5. Ancrage Narratif — Bible de la Série	17
6. Point de Vigilance — Contenu Sensible	18
Module 5 — Spécification des Métadonnées	19
1. Résumé Exécutif	19
2. Trois Familles d'Usage.....	19
3. Champs les Plus Critiques	19
4. Architecture — Flux d'Usage des Métadonnées	19
5. Décisions Techniques	19
6. Décisions Validées.....	19
Module 6 — Formats de Connaissance	21
1. Résumé Exécutif	21
2. Règle d'Or : PostgreSQL est la Source de Vérité Unique	21
3. Architecture — Flux entre Formats	21
4. Format Markdown (Rédaction)	21
5. Format JSON (Échange Canonique)	21
6. Schéma PostgreSQL (extrait)	22
7. Recommandation d'Usage par Contexte	22
8. Décisions Validées.....	22
Module 7 — Stratégie de Génération Synthétique de Connaissances.....	23
1. Résumé Exécutif	23
2. Sources Faisant Autorité.....	23

3. Architecture — Pipeline de Génération	23
4. Minimisation des Hallucinations	24
5. Validation Humaine — Rôles et Checklist	25
6. Lot Pilote — 18 Fiches Prioritaires.....	25
7. Décisions Validées.....	26
Module 8 — Architecture RAG	27
1. Résumé Exécutif	27
2. Architecture — Pipeline Complet	27
3. Points Clés du Pipeline.....	28
4. Construction du Prompt — Ordre de Priorité	29
5. Décisions Techniques	29
6. Décisions Validées.....	29
Module 9 — Couche de Sécurité du Gardien	30
1. Résumé Exécutif	30
2. Architecture — Les Couches de Sécurité	30
3. Couche 1 — Détection de Profil et Transparence	30
4. Couche 2 — Anonymisation.....	30
5. Couche 3 — Détection d'Urgence et Escalade	30
6. Couche 4 — Protection Anti-Injection et Anti-Jailbreak.....	30
7. Couches 7-8 — Validation Post-Génération et Repli	31
8. Modes par Profil.....	31
9. Décisions Validées.....	31
Module 10 — Intégration des LLM	32
1. Résumé Exécutif	32
2. Comparaison Structurelle	32
3. Architecture de Routage — GPT Principal.....	32
4. Budget API — Estimation.....	32
5. Estimation Budgétaire — Hébergement (2 premières années).....	32
6. Décisions Validées.....	33
Module 11 — Framework d'Évaluation.....	34
1. Résumé Exécutif	34
2. Datasets d'Évaluation	34
3. Benchmarks et KPIs.....	34
4. Évaluation Automatique vs Humaine.....	34
5. Architecture — Boucle d'Évaluation Continue.....	34
6. Monitoring de Coût.....	34
7. Décisions Validées.....	35
Module 12 — Feuille de Route de Déploiement.....	36
1. Résumé Exécutif	36
2. Architecture — Vue d'Ensemble des Phases.....	36
3. Détail des Phases	36

4. Recommandations Infrastructure par Phase 36

5. Risques 36

6. Recommandations Finales 36

Note : ce document a été conçu de façon progressive et collaborative, module par module, avec validation explicite du porteur de projet à chaque étape. Les décisions actées apparaissent en fin de chaque module sous l'intitulé « Décisions Validées ».

Module 0 — Configuration du Projet

Ce document constitue le blueprint technique complet de Guardian AI, l'assistant éducatif IA intégré à l'univers « Les Gardiens du Quartier » d'Africa Impact Studio. Il rassemble, dans l'ordre où elles ont été conçues et validées, la configuration initiale du projet, la charte de projet, puis les douze modules techniques couvrant la vision produit, l'architecture des connaissances, le pipeline RAG, la sécurité, l'intégration multi-LLM, l'évaluation et la feuille de route de déploiement.

Récapitulatif de Configuration

Élément	Détail
Langue du projet	Français (langue principale exclusive)
Nom du projet	Guardian AI — présenté aux utilisateurs sous le nom « Le Gardien »
Franchise associée	Les Gardiens du Quartier (Africa Impact Studio)
Étape de déploiement actuelle	Assistant IA intégré au site web d'Africa Impact Studio
Vision à long terme	Architecture conçue pour évoluer vers une plateforme IA autonome, sans refonte majeure
LLM supportés	GPT (principal), Gemini, Llama — architecture agnostique au modèle
Utilisateurs cibles	Enfants (6–9, 10–14, 15–18 ans), parents, enseignants, écoles, ONG, institutions gouvernementales
Pays prioritaires	Cameroun (lancement), extension prévue à d'autres pays africains
Conformité	Principes COPPA / RGPD pour la protection des données des mineurs, adaptés au contexte africain
Contraintes techniques	Connexion standard ; hébergement mondial sans contrainte de résidence stricte
Philosophie technique	Architecture RAG (Retrieval-Augmented Generation) — pas de chatbot à règles statiques

Mission :

« Guardian AI est une intelligence artificielle éducative conçue pour protéger, éduquer et responsabiliser les enfants, parents et enseignants à travers un savoir fiable, la sécurité numérique, la sécurité physique et les valeurs africaines. »

Charte de Projet

Vision

Faire de Guardian AI l'assistant éducatif IA de référence pour la protection, l'éducation numérique et l'épanouissement des enfants à travers l'Afrique — un compagnon de confiance qui grandit avec l'enfant, rassure les parents et soutient les enseignants, ancré dans les valeurs africaines et adossé à l'univers narratif Les Gardiens du Quartier.

Mission

Guardian AI est une intelligence artificielle éducative conçue pour protéger, éduquer et responsabiliser les enfants, parents et enseignants à travers un savoir fiable, la sécurité numérique, la sécurité physique et les valeurs africaines.

Objectifs

- Fournir des réponses fiables, adaptées à l'âge, sur la cybersécurité, la sécurité en ligne, la sécurité physique, la citoyenneté numérique et l'intelligence émotionnelle.
- Réduire l'exposition des enfants aux risques numériques via l'éducation préventive.
- Outiller les parents et enseignants avec des conseils actionnables.
- Ancrer chaque interaction dans l'univers narratif Les Gardiens du Quartier.
- Poser les fondations techniques d'une plateforme capable de passer d'un widget intégré à une solution panafricaine.

Périmètre

Inclus dans cette phase

- Assistant conversationnel intégré au site Africa Impact Studio.
- Architecture RAG multi-LLM (GPT, Gemini, Llama) avec base de connaissances Guardian.
- Adaptation par tranche d'âge et par profil (enfant, parent, enseignant).
- Couverture initiale : Cameroun, extensible à d'autres pays africains.

Hors périmètre pour cette phase

- Application mobile native.
- Mode hors ligne / faible bande passante.
- Intégration institutionnelle directe (écoles, gouvernements) — prévue en Module 12, pas en Phase 1.
- Collecte de données personnelles identifiables d'enfants au-delà du strict nécessaire conversationnel.

Indicateurs de Succès

Catégorie	Indicateur
Sécurité	0 réponse non filtrée sur les sujets à risque critique
Qualité éducative	Taux de réponses ancrées dans la base de connaissances ≥ 95 %
Adaptation	Taux de réponses adaptées à l'âge (évaluation humaine) ≥ 90 %

Catégorie	Indicateur
Confiance parentale	Satisfaction parents/enseignants sur la pertinence des conseils
Robustesse	Résistance aux tentatives de contournement (red-teaming)
Performance	Latence acceptable pour un usage web standard

Parties Prenantes

- Africa Impact Studio (porteur du projet, propriétaire de la franchise)
- Équipe technique
- Enfants utilisateurs (bénéficiaires finaux)
- Parents et enseignants
- Écoles et ONG partenaires
- Institutions gouvernementales / UNICEF (partenaires potentiels)
- Fournisseurs de LLM (OpenAI, Google, Meta / fournisseurs Llama)

Risques Principaux

Risque	Impact	Mitigation
Hallucination sur un sujet sensible	Élevé	Grounding RAG strict, couche de sécurité, réponses templates
Non-conformité juridique locale	Élevé	Validation juridique externe avant collecte de données réelles
Prompt injection / jailbreak	Moyen-Élevé	Couche de sécurité dédiée, red-teaming
Dépendance à un seul fournisseur LLM	Moyen	Architecture agnostique, routage multi-LLM
Biais culturels importés	Moyen	Base culturellement adaptée, relecteur culturel dédié
Détresse mal orientée par l'IA	Critique	Détection d'urgence + escalade humaine obligatoire

Principes Éthiques

- Aucune réponse ne doit isoler l'enfant d'un adulte de confiance.
- Aucune collecte de données personnelles au-delà du strict nécessaire.
- Escalade humaine systématique pour toute situation de détresse ou de danger.
- Transparence : l'enfant doit savoir qu'il parle à une IA.

Rappel important : cette charte pose un cadre éthique et technique rigoureux, mais la conformité légale réelle (COPPA/RGPD appliqués au Cameroun et autres pays visés) nécessite une validation juridique formelle avant tout déploiement traitant des données d'enfants.

Module 1 — Vision Produit, Mission, Périmètre, Objectifs

1. Résumé Exécutif

Ce module définit le socle produit de Guardian AI : ce qu'il est, pour qui, jusqu'où il va dans cette première phase, et comment on mesurera qu'il fonctionne. « Le Gardien » se présente de façon immersive dans l'univers narratif, avec une transparence non négociable sur sa nature d'IA.

2. Explication Détaillée

Ce qu'est Guardian AI

Un assistant conversationnel intégré au site Africa Impact Studio, ancré dans l'univers narratif Les Gardiens du Quartier, qui répond aux questions d'enfants, de parents et d'enseignants sur la sécurité numérique, la sécurité physique, la citoyenneté numérique et les compétences socio-émotionnelles — en s'appuyant sur une base de connaissances validée plutôt que sur la connaissance générale brute du LLM.

Ce que Guardian AI n'est pas

- Ce n'est pas un chatbot de divertissement générique.
- Ce n'est pas un service de conseil psychologique ou médical.
- Ce n'est pas un canal d'urgence — il oriente vers des adultes de confiance et des ressources humaines réelles.
- Ce n'est pas (encore) une plateforme autonome — c'est un widget intégré.

3. Architecture — Vue Produit




Figure 1 — Flux produit : de l'utilisateur à la réponse générée, en passant par l'adaptation de profil et la couche de sécurité.

4. Décisions Techniques

Décision	Justification
Détection de profil obligatoire avant toute réponse substantielle	Une même question appelle une réponse très différente selon l'âge
Séparation stricte mode Enfant / mode Adulte	Évite qu'un enfant reçoive un conseil formulé pour un parent
Aucune réponse sur sujet sensible sans passage par la base de connaissances	Empêche le LLM de « broder » sur des sujets sensibles
Widget intégrable, pas app séparée en Phase 1	Réduit la friction d'adoption, cohérent avec la feuille de route

5. Compromis

- Simplicité d'intégration vs richesse fonctionnelle : widget web limite certaines fonctionnalités mais accélère le déploiement.
- Sécurité stricte vs fluidité conversationnelle : l'ancrage RAG systématique prime sur le naturel absolu du dialogue.
- Couverture multi-pays vs qualité d'adaptation fine par pays.

6. Risques

- Ambiguïté de profil : un enfant se faisant passer pour un adulte pourrait recevoir un contenu mal calibré (traité au Module 9).
- Attentes désalignées des parties prenantes sur des fonctionnalités hors périmètre.

7. Recommandations

- Documenter explicitement dans l'interface que Guardian AI est une IA éducative, non un service d'urgence.
- Question d'auto-déclaration de profil simple et rassurante à l'entrée de la conversation.
- Garder le mode Enseignant distinct du mode Parent.

8. Décisions Validées avec le Porteur de Projet

- Le mode Enseignant se concentre sur la gestion de crise et de situations dangereuses en classe, pas sur la gestion administrative.
- L'assistant se présente sous le nom « Le Gardien », de façon immersive, avec la transparence de sa nature d'IA énoncée dès le premier message.

Module 2 — Exigences Fonctionnelles

1. Résumé Exécutif

Ce module traduit la vision produit en capacités concrètes : ce que « Le Gardien » doit savoir faire, pour qui, avec quelles limites explicites — en intégrant le mode Enseignant orienté gestion de crise et la présentation immersive validés au Module 1.

2. User Stories

Enfant (6–9 ans)

- Demander à Le Gardien si un message reçu en ligne est dangereux, pour savoir s'il faut en parler à un adulte.
- Que Le Gardien parle comme un personnage du dessin animé, pas comme un adulte sévère.

Enfant (10–14 ans)

- Comprendre comment protéger ses mots de passe et reconnaître une arnaque en ligne.
- Poser des questions sur le harcèlement scolaire sans craindre d'être jugé.

Enfant (15–18 ans)

- Conseils concrets sur la protection de la vie privée et la gestion de conflits en ligne.

Parent

- Conseils pratiques pour parler à son enfant d'un danger en ligne sans le brusquer.
- Savoir quand une situation nécessite l'intervention d'un professionnel.

Enseignant

- Un protocole clair quand un élève révèle une situation dangereuse.
- Aide pour aborder un sujet de sécurité numérique avec toute la classe.
- Distinguer une situation gérable en classe d'une situation nécessitant une escalade immédiate.

3. Capacités

Capacité	Description
Réponse éducative adaptée à l'âge	Cybersécurité, sécurité en ligne/physique, citoyenneté numérique
Détection de situation sensible	Identification de signaux de danger, harcèlement, détresse
Orientation vers ressources humaines	Redirection systématique vers adulte de confiance / ligne d'écoute
Mode Parent	Suggestions de formulations pour dialoguer avec l'enfant
Mode Enseignant — protocole de crise	Évaluer / Agir / Escalader, sans remplacer le jugement humain
Ancrage narratif	Réponses référençant épisodes/personnages des Gardiens du Quartier
Multilingue (évolutif)	Français en priorité, extensible

4. Limitations Explicites

- Le Gardien ne diagnostique pas, ne fait pas de suivi psychologique.
- Le Gardien n'intervient pas directement en cas d'urgence — il informe et oriente.
- Le mode Enseignant fournit une aide à la décision, pas un protocole légalement contraignant.
- Aucune donnée identifiante d'enfant stockée au-delà du strict nécessaire.

5. Cas d'Usage

Cas d'usage	Résumé
UC-1	Enfant signale un comportement suspect en ligne — évaluation du risque, ton rassurant, recommandation d'en parler à un adulte
UC-2	Enseignant face à une révélation en classe — structuration Évaluer/Agir/Escalader
UC-3	Parent cherche à aborder un sujet difficile — formulations concrètes, référence narrative
UC-4	Question éducative simple — réponse directe ancrée dans la base

6. Exigences Non-Fonctionnelles

Catégorie	Exigence
Latence	Réponse fluide pour un usage web conversationnel
Disponibilité	Service disponible en continu pendant les heures scolaires a minima
Auditabilité	Chaque réponse sensible tracée (source, score de confiance, horodatage)
Confidentialité	Aucune donnée identifiante stockée sans nécessité stricte
Résilience multi-LLM	Basculer automatique sans dégradation de la sécurité
Cohérence de ton	Voix de personnage cohérente à travers les tranches d'âge

7. Décisions Validées

- Le mode Enseignant en situation de crise référence des procédures génériques (pas d'institutions nommées, car cela varie par pays/école).
- Le Gardien conserve la mémoire du contexte pendant la durée d'une conversation donnée.

Module 3 — Architecture Complète des Connaissances

1. Résumé Exécutif

Ce module définit comment la connaissance du Gardien est organisée, structurée, maintenue et gouvernée — la fondation qui rend le RAG fiable. La dimension « Valeurs Africaines et Civisme » est traitée comme transversale, appliquée à tous les domaines plutôt que comme catégorie séparée.

2. Séparation Contenu Éducatif / Contenu Protocole

Deux grandes familles de connaissances coexistent avec des cycles de vie et niveaux de validation différents : la Connaissance Éducative (« qu'est-ce que... », « comment... », destinée à l'usage courant) et la Connaissance Protocole (« que faire si... », destinée au mode Enseignant/Parent en situation de crise).

3. Architecture — Taxonomie des Connaissances




Figure 2 — Taxonomie complète de la base de connaissances Guardian, avec la dimension Valeurs Africaines traitée en transversal.

4. Domaines de Connaissance

Domaine	Sous-domaines principaux	Utilisateur principal
Sécurité Numérique	Mots de passe, arnaques, confidentialité, cyberharcèlement, IA responsable	Enfants 10-18, Parents
Sécurité Physique	Maison, communauté, reconnaissance de danger	Enfants 6-14, Parents
Citoyenneté Numérique	Respect en ligne, désinformation, empreinte numérique	Enfants 10-18
Intelligence Émotionnelle	Gestion des émotions, communication, empathie	Tous âges
Protocoles Enseignant	Détection, évaluation, escalade	Enseignants
Protocoles Parent	Dialogue, accompagnement	Parents
Narratif	Personnages, épisodes, univers	Support transversal

5. Hiérarchie de la Connaissance

Chaque fiche existe à plusieurs niveaux d'abstraction : Domaine → Catégorie → Sous-catégorie → Scénario → Variante par âge → Variante par profil. Cette hiérarchie à 5 niveaux permet au retriever (Module 8) de remonter à un niveau plus général si aucune fiche ne correspond exactement, évitant l'absence de réponse ou l'hallucination par manque de contenu source.

6. Cycle de Vie de la Connaissance




Figure 3 — Cycle de vie d'une fiche Guardian, de l'identification du besoin à l'archivage.

7. Gouvernance

Aspect	Règle
Propriétaire du contenu	Africa Impact Studio, avec comité de validation externe possible
Révision — Éducatif	Semestrielle, ou déclenchée par feedback
Révision — Protocole	Trimestrielle, ou immédiate si un incident réel révèle une lacune
Statut de chaque fiche	Brouillon → En révision → Publié → Obsolète → Archivé
Validation requise	Éducatif : 1 réviseur / Protocole : 2 réviseurs

8. Décisions Validées

- « Valeurs Africaines et Civisme » est une dimension transversale appliquée à tous les domaines, pas une catégorie séparée.
- Le contenu Narratif est directement alimenté par la bible existante des personnages et épisodes Les Gardiens du Quartier.

Module 4 — Schéma de Connaissance Guardian

1. Résumé Exécutif

Ce module traduit la taxonomie du Module 3 en un schéma de champs concret. Chaque fiche Guardian doit être auto-suffisante pour le retriever (Module 8) : ses métadonnées seules doivent permettre de décider de sa pertinence, sans relire tout son contenu.

2. Schéma Complet — Champs et Spécifications

2.1 Identification et Classification

Champ	Type	Exemple
id	UUID	gdn-0001a3f2
topic	String	Reconnaître un message suspect en ligne
category	Enum	securite_numerique
subcategory	Enum	cyberharcèlement
knowledge_type	Enum	educatif / protocole / narratif
scenario	String	Un inconnu envoie des messages répétés à un enfant
intent	Enum	demande_conseil / signalement / information_generale

2.2 Ciblage et Adaptation

Champ	Type	Exemple
age_group	Enum multi	6-9 / 10-14 / 15-18 / parent / enseignant
user_profile	Enum multi	enfant / parent / enseignant
risk_level	Enum	faible / modéré / élevé / critique
dimension_culturelle	String (optionnel)	Importance de la famille élargie
cultural_adaptation	String (optionnel)	null en Phase 1 (Cameroun uniquement)

2.3 Contenu Pédagogique

- objectif_educatif — ce que l'utilisateur doit comprendre/retenir
- resultat_apprentissage — compétence ou réflexe acquis
- contenu_principal — corps de la réponse-source, formulé de façon neutre
- conseils_parent / conseils_enseignant — angle spécifique par profil adulte
- conseil_securite — recommandation actionnable
- escalade_urgence — obligatoire si risk_level = critique

2.4 Ancrage Narratif

- personnage_reference, episode_reference, saison_reference, phrase_signature
- trait_associe — la faille/force du personnage que la fiche mobilise
- arc_saison — Découvrir / Comprendre / Devenir

- lecon_episode — leçon explicite de fin d'épisode, quasi directement réutilisable comme objectif_educatif

2.5 Sources, Validation et Gouvernance

- references, sources_autorite, keywords, tags, difficulty
- version, review_status, quality_score (évolutif avec l'usage), created_at/updated_at, reviewed_by, next_review_date

3. Architecture — Relations entre Blocs du Schéma




Figure 4 — Consommation du schéma par les composants du pipeline (retriever, générateur, sécurité, gouvernance).

4. Décisions Techniques

Décision	Justification
escalade_urgence obligatoire si risk_level critique	Contrainte de schéma empêchant la publication sans orientation humaine
dimension_culturelle optionnelle mais visible	Reflète le caractère transversal validé au Module 3
reviewed_by par rôle, pas par identité	Minimisation des données même en interne

5. Ancrage Narratif — Bible de la Série

Le schéma est directement alimenté par la bible narrative des Gardiens du Quartier : cinq enfants (Ahmad, Sarah, Ily, Yusuf, Junior), chacun porteur d'une force et d'une faille claires, encadrés par l'Inspectrice Fatima, sur trois saisons structurées autour du triptyque Découvrir / Comprendre / Devenir. Cette richesse narrative permet une sélection automatique du personnage le plus pertinent pour une situation donnée, via le champ trait_associe (ex. Sarah — impulsivité et besoin d'aide — pour une fiche sur la demande d'aide).

Personnage	Trait dominant → Faille	Arc narratif
Ahmad (13 ans)	Leader, sens de la justice → porte tout seul	Contrôle solitaire → leadership partagé
Sarah (12 ans)	Courage, protection → impulsivité	Courage impulsif → courage qui sait demander de l'aide
Ily (11 ans)	Observatrice, analyste → timidité	Silence observateur → voix qui compte
Yusuf (13 ans)	Génie technique → introversion	Technologie refuge → technologie au service des autres

Personnage	Trait dominant → Faille	Arc narratif
Junior (10 ans)	Optimiste, gentil → naïveté	Enfant protégé → enfant qui protège
Inspectrice Fatima	Autorité qui écoute → perfectionnisme	Gagner la confiance → mentor institutionnel

6. Point de Vigilance — Contenu Sensible

La règle éditoriale de la série (le « Réseau », antagoniste de la Saison 1, n'est jamais montré de façon spectaculaire ou glorifiée) est reportée comme contrainte de sécurité de contenu au Module 9 : Le Gardien ne doit jamais donner de détail opérationnel sur « comment un manipulateur agit » au-delà de ce qui est strictement protecteur.

Module 5 — Spécification des Métadonnées

1. Résumé Exécutif

Ce module explique, pour chaque champ du Module 4, pourquoi il existe et comment il est concrètement utilisé par les composants du système. Une métadonnée sans consommateur technique réel est une dette de maintenance, pas un atout.

2. Trois Familles d'Usage

- Filtrage/Recherche — utilisé par le retriever avant même de regarder le contenu
- Génération — utilisé pour construire le prompt final envoyé au LLM
- Sécurité & Gouvernance — utilisé pour bloquer, escalader, auditer, réviser

3. Champs les Plus Critiques

Champ	Pourquoi	Utilisation
knowledge_type	Détermine le niveau d'exigence de validation	Route différemment une requête selon Éducatif/Protocole/Narratif
risk_level	Champ le plus critique du point de vue sécurité	Déclenche le contrôle obligatoire d'escalade si critique
review_status	Empêche l'usage d'une fiche non validée	Filtre non-contournable du retriever — seul « publié » est éligible
quality_score	Priorise les fiches pertinentes multiples	Facteur de reranking, désormais évolutif avec le feedback utilisateur
age_group / user_profile	Cœur du principe d'adaptation	Filtre de retrieval + paramètre de prompt

4. Architecture — Flux d'Usage des Métadonnées




Figure 5 — De la requête utilisateur au log de réponse, en passant par le filtrage, la recherche hybride et le reranking.

5. Décisions Techniques

Décision	Justification
review_status comme filtre non-contournable	Sécurité avant tout, même en environnement de test
Champs narratifs jamais source de vérité factuelle	Empêche qu'une réponse de sécurité dépende d'un choix esthétique
quality_score distinct de review_status	Un contenu publié peut être moins performant qu'un autre

6. Décisions Validées

- quality_score évolue automatiquement avec l'usage (taux de satisfaction 👍 / 👎), plutôt que fixé uniquement à la publication.

- La détection de profil (enfant/parent/enseignant) est tranchée au Module 9, où elle rejoint les autres décisions de sécurité.

Module 6 — Formats de Connaissance

1. Résumé Exécutif

Ce module définit comment une fiche Guardian s'incarne selon le format utilisé : Markdown pour la rédaction humaine, JSON/JSONL pour l'échange, PostgreSQL comme source de vérité, pgvector pour la recherche sémantique, YAML pour la configuration, CSV pour la revue externe.

2. Règle d'Or : PostgreSQL est la Source de Vérité Unique

Tous les autres formats sont soit des vues dérivées de PostgreSQL (JSON d'export, vecteurs), soit des entrées qui l'alimentent après validation (Markdown rédigé par un humain). Cela évite le problème classique de synchronisation entre plusieurs sources de vérité concurrentes.

3. Architecture — Flux entre Formats




Figure 6 — PostgreSQL comme pivot central : entrées validées en amont, vues dérivées en aval.

4. Format Markdown (Rédaction)

```

---
id: gdn-0001a3f2
topic: "Reconnaître un message suspect en ligne"
category: securite_numerique
subcategory: cyberharcèlement
knowledge_type: educatif
age_group: [10-14]
user_profile: [enfant, parent]
risk_level: modere
personnage_reference: Sarah
review_status: brouillon
---

## Scénario
Un inconnu envoie des messages répétés à un enfant sur un réseau social.

## Objectif éducatif
Apprendre à reconnaître les signaux d'un contact suspect en ligne.
  
```

5. Format JSON (Échange Canonique)

```
{
```

```

    "id": "gdn-0001a3f2",
    "topic": "Reconnaître un message suspect en ligne",
    "category": "securite_numerique",
    "knowledge_type": "educatif",
    "risk_level": "modere",
    "age_group": ["10-14"],
    "user_profile": ["enfant", "parent"],
    "contenu_principal": "...",
    "personnage_reference": "Sarah",
    "review_status": "brouillon",
    "quality_score": null
  }

```

6. Schéma PostgreSQL (extrait)

```

CREATE TABLE guardian_fiches (
  id UUID PRIMARY KEY,
  topic TEXT NOT NULL,
  category TEXT NOT NULL CHECK (category IN (
    'securite_numerique', 'securite_physique',
    'citoyennete_numerique', 'intelligence_emotionnelle')),
  risk_level TEXT NOT NULL CHECK (risk_level IN (
    'faible', 'modere', 'eleve', 'critique')),
  contenu_principal TEXT NOT NULL,
  escalade_urgence TEXT,
  review_status TEXT NOT NULL DEFAULT 'brouillon',
  quality_score FLOAT DEFAULT NULL,
  CONSTRAINT escalade_obligatoire_si_critique
    CHECK (risk_level != 'critique' OR escalade_urgence IS NOT NULL)
);

```

7. Recommandation d'Usage par Contexte

Contexte	Format
Expert rédige une nouvelle fiche	Markdown avec frontmatter
Import en masse (Module 7)	JSONL
Stockage durable, contraintes de sécurité	PostgreSQL
Recherche au moment de la requête	Base vectorielle pgvector (dérivée)
Configuration du comportement système	YAML
Revue par un comité ONG/école non technique	CSV — commentaire de statut uniquement

8. Décisions Validées

- Couche d'anonymisation renforcée au-delà du texte brut, indépendamment du lieu d'hébergement.
- Hébergement mondial, sans contrainte stricte de résidence africaine (simplification assumée pour la Phase 1).
- Le canal CSV de revue externe (ONG/écoles) permet uniquement de commenter le statut, jamais de modifier le contenu directement — champ commentaire_revision dédié à cet effet.

Module 7 — Stratégie de Génération Synthétique de Connaissances

1. Résumé Exécutif

Ce module définit comment la base de connaissances Guardian sera produite efficacement sans sacrifier la fiabilité factuelle. La génération assistée par IA accélère la rédaction ; elle ne remplace jamais la validation humaine.

2. Sources Faisant Autorité

Domaine Guardian	Sources recommandées
Sécurité numérique / cybersécurité	NIST, CISA, ENISA, OWASP
Sécurité en ligne des enfants	Common Sense Media, ChildNet, Internet Matters, Google/Meta/Microsoft Safety Center
Sécurité physique / protection de l'enfance	UNICEF, OMS, Croix-Rouge
Santé mentale / intelligence émotionnelle	OMS, UNICEF
Citoyenneté numérique / désinformation	UNESCO, Common Sense Media

Note de prudence : chaque source devra être consultée directement et citée précisément au moment de la génération réelle, pas résumée de mémoire par le LLM.

3. Architecture — Pipeline de Génération




Figure 7 — Du besoin identifié à la publication, avec double validation obligatoire pour le contenu Protocole.

4. Minimisation des Hallucinations

Méthode	Application
Génération ancrée sur extraits sourcés	Jamais de rédaction depuis la mémoire générale du LLM
Séparation génération / vérification	Un second passage vérifie les affirmations contre les sources citées
Trame fixe pour le contenu Protocole	Les étapes de procédure sont un squelette invariant
Interdiction de chiffres non sourcés	Toute donnée chiffrée doit être traçable, sinon supprimée en revue
Test de contradiction croisée	Vérifie qu'une nouvelle fiche ne contredit pas une fiche existante

5. Validation Humaine — Rôles et Checklist

- Expert pédagogique — adéquation à l'âge, clarté, objectifs d'apprentissage.
- Expert sécurité/protection de l'enfance — justesse du risk_level, pertinence de l'escalade.
- Relecteur culturel (Cameroun/Afrique) — pertinence de la dimension_culturelle, absence de biais importé.

6. Lot Pilote — 18 Fiches Prioritaires

Sélection conçue pour stress-tester le pipeline sur les cas les plus exigeants en premier, couvrant les 4 niveaux de risque, les 3 tranches d'âge, les deux types de connaissance, et exploitant la bible narrative existante.

#	Sujet	Risk level	Ancrage narratif
1	Reconnaître un message suspect d'un inconnu en ligne	modéré	Ép. 1 (transposé au numérique)
2	Créer et protéger un mot de passe fort	faible	Yusuf
3	Reconnaître une arnaque en ligne	modéré	—
4	Cyberharcèlement — capture d'écran humiliante partagée	élevé	Saison 2, Cabane des Gardiens
5	Ce qu'il ne faut jamais partager en ligne	modéré	—
6	Usage responsable de l'IA	faible	Yusuf
7	Un inconnu propose d'accompagner l'enfant	critique	Ép. 1 (Junior)
8	Se perdre dans un lieu public	élevé	Marché central
9	Reconnaître un danger à la maison	critique	Inspectrice Fatima
10	Dire non à un adulte qui demande le secret	critique	—
11	Reconnaître une fausse nouvelle	faible	Saison 2, page de rumeurs
12	Gérer la pression des pairs en ligne	modéré	Tom et Théo
13	Demander de l'aide au lieu de tout garder pour soi	modéré	Sarah
14	Oser prendre la parole	modéré	Ily
15	Protocole — révélation de danger à la maison	critique	—
16	Protocole — cyberharcèlement collectif en classe	élevé	—
17	Protocole — contenu inapproprié partagé en classe	élevé	—
18	Protocole Parent — enfant contacté par un inconnu en ligne	élevé	—

7. Décisions Validées

- Les rôles d'expert pédagogique, expert sécurité, et relecteur culturel restent à constituer (bénévoles / partenaires ponctuels).
- Le lot pilote de 18 fiches ci-dessus sert de point de départ concret, ajustable une fois les relecteurs identifiés.

Module 8 — Architecture RAG

1. Résumé Exécutif

Ce module assemble tous les blocs précédents en un pipeline RAG de production complet, de la question posée jusqu'à la réponse affichée. Principe de conception : chaque étape peut bloquer, jamais deviner.

2. Architecture — Pipeline Complet




Figure 8 — Pipeline RAG complet : anonymisation, détection de profil, recherche hybride, reranking, génération, validation post-génération.

3. Points Clés du Pipeline

- Pas de chunking automatique — la fiche Guardian est déjà l'unité de récupération atomique.
- Recherche hybride (lexicale 30% + sémantique 70%) — capture aussi bien le vocabulaire exact que l'intention reformulée.
- Reranking pondéré par `quality_score` — priorise les fiches les mieux évaluées à pertinence égale.
- Fallback sûr systématique — si aucune fiche pertinente n'est trouvée, jamais de réponse improvisée du LLM sur un sujet sensible.
- Vérification post-génération indépendante du modèle utilisé — sécurité uniforme malgré le multi-LLM.

4. Construction du Prompt — Ordre de Priorité

- 1. Instruction système fixe (ton « Le Gardien », contraintes de sécurité non négociables)
- 2. `contenu_principal` de la/les fiche(s) retenue(s) — source factuelle
- 3. `conseils_parent` / `conseils_enseignant` selon le profil détecté
- 4. Élément narratif — marqué explicitement comme habillage stylistique, jamais comme source factuelle
- 5. Instruction stricte de ne jamais répondre hors du contenu fourni pour les sujets à risque élevé/critique

5. Décisions Techniques

Décision	Justification
pgvector comme moteur vectoriel (Phase 1)	Intégration directe à PostgreSQL, simplicité maximale à cette échelle
Feedback utilisateur simple 👍 / 👎	Suffisant en Phase 1, alimente directement le <code>quality_score</code> évolutif
Fallback sûr plutôt que réponse « au mieux »	Bloquer plutôt que deviner sur un sujet sensible

6. Décisions Validées

- Moteur de base vectorielle : pgvector pour la Phase 1.
- Mécanisme de feedback utilisateur : échelle simple 👍 / 👎.

Module 9 — Couche de Sécurité du Gardien

1. Résumé Exécutif

Module le plus critique du blueprint : défense en profondeur, pas un filtre unique. Chaque couche existe pour rattraper une défaillance possible de la couche précédente.

2. Architecture — Les Couches de Sécurité



Figure 9 — Les huit couches de sécurité successives, de la détection de profil aux templates de repli.

3. Couche 1 — Détection de Profil et Transparence

Déclaration explicite légère via interface à boutons/pictogrammes (adaptée aux jeunes enfants qui lisent moins bien), mémorisée pour la durée de la conversation. En cas d'ambiguïté, le système applique par défaut le mode le plus prudent.

Message de transparence validé : « Salut, je suis Le Gardien ! Je suis une intelligence artificielle qui connaît bien les histoires des Gardiens du Quartier, et je suis là pour répondre à tes questions et t'aider à rester en sécurité. »

4. Couche 2 — Anonymisation

Élément retiré avant tout traitement externe	Méthode
Noms propres (enfant, famille, école, quartier)	Détection d'entités nommées + remplacement générique
Coordonnées (téléphone, adresse)	Détection par pattern + suppression
Identifiants de session	Jamais transmis dans le contenu du message

5. Couche 3 — Détection d'Urgence et Escalade

Situation	Formulation type
Danger général signalé par un enfant	« C'est important que tu en parles tout de suite à un adulte de confiance. »
Danger immédiat / urgence	« Ceci est important et urgent. Va voir un adulte proche, ou demande à quelqu'un d'appeler les secours. »
Signalement par un enseignant	« Cette situation doit être signalée à la direction, selon le protocole de votre école. »
Détresse émotionnelle exprimée	« Ce que tu ressens compte. Parle-en à un adulte de confiance. »

Formulations volontairement génériques (pas de numéro de téléphone spécifique), à affiner ultérieurement avec les partenaires locaux — décision validée avec le porteur de projet.

6. Couche 4 — Protection Anti-Injection et Anti-Jailbreak

- Instructions système non modifiables par le contenu utilisateur, détection de patterns d'injection connus.
- Rappel systématique du périmètre du Gardien, non contournable par roleplay.
- Jamais de récitation du prompt système, même sous insistance.

- Le risk_level du contenu reste prudent indépendamment du profil déclaré — une fausse déclaration ne débloquent pas de contenu dangereux.

7. Couches 7-8 — Validation Post-Génération et Repli

- Vérification : présence de l'escalade attendue, absence de contradiction avec la source, ton adapté à l'âge.
- En cas d'échec : régénération une fois, puis template de repli pré-écrit — jamais de boucle indéfinie, jamais de message technique brut visible par l'enfant.

8. Modes par Profil

Mode	Comportement spécifique
Enfant	Ton immersif « Le Gardien », escalade systématique, jamais de détail opérationnel sur un danger
Parent	Ton direct, conseils de dialogue, moins d'habillage narratif
Enseignant	Structure Évaluer/Agir/Escalader, procédures génériques uniquement
Institution	Hors périmètre Phase 1, anticipé pour le Module 12

9. Décisions Validées

- Déclaration de profil via interface à boutons/pictogrammes.
- Message de transparence sur la nature IA validé tel quel.

Module 10 — Intégration des LLM

1. Résumé Exécutif

Ce module compare GPT, Gemini et Llama et propose une architecture de routage cohérente avec l'inférence uniquement (Module 7), l'hébergement mondial (Module 6), pgvector (Module 8) et la sécurité uniforme (Module 9).

Note de prudence : les tarifs et performances exacts évoluent rapidement — à vérifier au moment de l'implémentation réelle plutôt qu'à figer ici.

2. Comparaison Structurelle

Critère	GPT	Gemini	Llama
Contrôle hébergement /	Fermé, API uniquement	Fermé, API uniquement	Ouvert — auto-hébergeable ou API
Coût structurel	Généralement plus élevé	Compétitif	Généralement le plus bas via API tierces
Intégration RAG	Excellente (function calling mature)	Bonne	Bonne, dépend du fournisseur
Risque de dépendance	Élevé si utilisé seul	Élevé si utilisé seul	Réduit — portabilité entre fournisseurs

3. Architecture de Routage — GPT Principal



Figure 10 — Routage par criticité : GPT en principal et en modèle premium pour le risque élevé, Llama puis Gemini en cascade de secours.

4. Budget API — Estimation

Scénario	Budget annuel	Budget mensuel
Réparti sur 2 ans (recommandé)	≈ 2 615 USD/an (≈ 1 500 000 FCFA/an)	≈ 218 USD/mois
Concentré sur 1 an	≈ 5 230 USD/an (≈ 3 000 000 FCFA)	≈ 436 USD/mois

Enveloppe totale de référence : 3 000 000 FCFA (≈ 5 230 USD au taux de juillet 2026), répartie sur 2 ans. GPT étant plus coûteux que Llama, le routage par criticité (section 3) devient aussi la stratégie d'optimisation budgétaire : GPT en principal avec une variante économique pour les requêtes standards, Llama en premier recours de secours (coût et disponibilité), Gemini en second recours.

5. Estimation Budgétaire — Hébergement (2 premières années)

Poste	Estimation mensuelle	Estimation annuelle
PostgreSQL + pgvector managé (offre d'entrée de gamme)	≈ 15-30 USD	≈ 180-360 USD
Backend applicatif (VPS ou serverless économique)	≈ 10-25 USD	≈ 120-300 USD

Poste	Estimation mensuelle	Estimation annuelle
Stockage logs/monitoring léger	≈ 0-10 USD	≈ 0-120 USD
Total estimé Phase 1	≈ 25-65 USD/mois	≈ 300-780 USD/an

Sur 2 ans : environ 600 à 1 560 USD d'hébergement. Budget global combiné (API + hébergement) sur 2 ans : environ 3 200 à 4 200 USD, dans l'enveloppe totale de ~5 230 USD, avec une marge de sécurité. Ces fourchettes sont à valider avec des devis réels au moment de l'implémentation.

6. Décisions Validées

- Modèle principal pour le lancement : GPT.
- Llama en premier fallback, Gemini en second fallback.
- Budget API réparti sur 2 ans (≈ 218 USD/mois), avec stratégie de routage économique pour tenir le budget.

Module 11 — Framework d'Évaluation

1. Résumé Exécutif

Ce module définit comment mesurer objectivement si Guardian AI fonctionne — techniquement, pédagogiquement, et surtout en sécurité. La sécurité et la qualité générale ne sont jamais fusionnées dans un score unique.

2. Datasets d'Évaluation

- Lot pilote de référence — les 18 fiches du Module 7, pour le test de non-régression.
- Jeu de red-teaming sécurité — tentatives de contournement (jailbreaks, fausses déclarations de profil).
- Jeu de diversité linguistique — vocabulaire réel d'enfants de différents âges.
- Jeu de cohérence narrative — fidélité aux personnages/épisodes de la bible.

3. Benchmarks et KPIs

Catégorie	KPI	Cible indicative
Sécurité	Rappel de détection des signaux d'urgence	Proche de 100%
Sécurité	Faux négatifs sur le jeu de red-teaming	0 toléré avant mise en production
Qualité éducative	Réponses ancrées dans la base (sans hallucination)	≥ 95%
Adaptation	Réponses adaptées à l'âge (évaluation humaine)	≥ 90%
Coût	Coût moyen par requête	Suivi dès le pilote
Latence	Temps de réponse bout-en-bout	Mesuré par étape

4. Évaluation Automatique vs Humaine

Type	Ce qu'elle couvre	Fréquence
Automatique	Ancrage factuel, présence d'escalade, latence, coût	Continue, chaque requête
Humaine — experts	Qualité pédagogique, ton, pertinence culturelle	Échantillon de 20% des conversations
Humaine — red-teaming dédié	Résistance aux contournements de sécurité	Avant chaque mise en production majeure

5. Architecture — Boucle d'Évaluation Continue




Figure 11 — Boucle continue : production, feedback, évaluation automatique, alerte, revue experte, ajustement de la base.

6. Monitoring de Coût

Alerte	Seuil	Action
Consommation mensuelle	70% du budget (≈ 153 USD)	Notification, revue du routage
Consommation mensuelle	90% du budget (≈ 196 USD)	Bascule automatique renforcée vers Llama
Dépassement projeté	Extrapolation du rythme quotidien	Alerte préventive avant 70%

7. Décisions Validées

- Red-teaming sécurité assuré par les mêmes bénévoles/experts que le Module 7.
- Échantillon de revue humaine fixé à 20% des conversations en Phase 1.

Module 12 — Feuille de Route de Déploiement

1. Résumé Exécutif

Ce dernier module traduit les onze modules précédents en un calendrier de déploiement phasé, avec des critères de passage explicites entre chaque étape — chaque phase a une porte de sortie, pas une date fixe.

2. Architecture — Vue d'Ensemble des Phases




Figure 12 — Les cinq phases de déploiement de Guardian AI, du prototype à l'expansion panafricaine.

3. Détail des Phases

Phase	Contenu	Critères de sortie
1. Prototype	Widget + 18 fiches pilotes + pipeline RAG complet + sécurité validée par red-teaming	0 faux négatif sécurité ; ancrage ≥ 95% ; budget conforme
2. Pilote écoles	Extension à des écoles partenaires au Cameroun, mode Enseignant en conditions réelles	Retours enseignants positifs ; aucun incident non détecté
3. Déploiement régional	Couverture élargie au Cameroun, implication ONG formalisée	Validation juridique locale ; stabilité sur plusieurs mois
4. Déploiement national	Couverture nationale, mode Institution, partenariats gouvernementaux	Partenariats formalisés ; infrastructure redimensionnée
5. Expansion panafricaine	Autres pays, cultural_adaptation activé, escalades localisées par pays	Trios d'experts locaux constitués par pays

4. Recommandations Infrastructure par Phase

Phase	Infrastructure recommandée
1-2	Services managés économiques (Supabase/Neon/Render) — suffisant pour un volume pilote
3	Réévaluation vers des offres intermédiaires si le volume le justifie
4-5	Architecture à redimensionner complètement — sujet d'un futur cycle de conception dédié

5. Risques

- Sous-estimation du temps nécessaire pour recruter des trios d'experts locaux lors de l'expansion panafricaine.
- Dépendance à la disponibilité bénévole des experts — un plan de sauvegarde pourrait être nécessaire à terme.

6. Recommandations Finales

- Ne pas sous-estimer la Phase 1 : elle valide ou invalide toutes les hypothèses de sécurité posées dans les modules précédents.

- Documenter systématiquement les apprentissages de chaque phase pour alimenter la révision de ce blueprint — ce document n'est pas figé.

Fin du Blueprint Technique de Guardian AI — Modules 0 à 12.

Ce document couvre l'intégralité de la conception initiale du projet. Chaque décision marquée « Décisions Validées » dans les modules ci-dessus reflète un choix explicitement confirmé par le porteur de projet au cours de l'élaboration de ce blueprint. Les points restés ouverts (recrutement des experts bénévoles, nombre d'écoles pour la Phase 2, devis d'hébergement réels) sont signalés comme tels et devront être tranchés au fil de l'avancement du projet.